

Instruccions per fer servir l'agent de Copilot **Assistent CQS SAIEP**

(Assistent per a la plataforma de consultes, queixes i suggeriments del Servei d'Autorització d'Instal·lacions Elèctriques de Producció).

Versió inicial feta per Àngel Morales Cirera

(angelmorales@gencat.cat | angel.morales@estudiantat.upc.edu)

Introducció

En aquest document s'explica com fer servir l'assistent i unes directrius bàsiques per maximitzar l'eficiència, esprémer el potencial, i minimitzar els riscos.

L'accés a l'assistent pot estar restringit a una llista de persones específiques.

Aspectes importants a conèixer

Aquest agent de Copilot Xat té l'objectiu d'accelerar el procés de donar resposta a una consulta ciutadana a través del CQS, fent eficient tant la cerca d'informació necessària per donar resposta com la síntesi d'aquesta resposta.

Principals riscos

És **primordial comprendre** que aquest assistent està basat en **intel·ligència artificial**, per tant, no pensa com una persona i no es comporta com una persona, encara que el seu raonament s'assembli al que fem nosaltres. Les diferències clau són aquestes:

- **No pot fer-se responsable** de les conseqüències d'allò que fa. Sempre s'haurà de fer servir com una eina d'assistència, i mai no podrem delegar-li cap mena de responsabilitat.
- **Pot cometre errors** que una persona és més difícil que cometi, i d'una forma que els fa difícils de percebre, com ara:

- **Al·lucinacions:** inventar-se sense voler informació que no és certa, com ara una llei o un article d'una llei, i fer-la servir com si existís de veritat. Si bé una persona també pot confondre's i inventar-se afirmacions, els errors humans acostumen a ser puntuals (per exemple confondre una data, un nom, una llei...), però una al·lucinació d'una IA a vegades comporta crear tota una escena fictícia sencera (com ara inventar-se l'existència d'un article d'una llei). Això ens pot resultar confús i pot ser més difícil adonar-se'n, ja que típicament una persona només faria això de forma deliberada per mentir.
- **Pot tenir un comportament molt diferent del d'una persona.** Per exemple, **una IA acostuma a respondre sempre** a una pregunta que se li faci, **en comptes de dir que “no ho sap”** com fa una persona. Per aconseguir que una IA no doni resposta (digui “no ho sé”) se li ha de demanar específicament, per exemple demanant-li que “respongui que no té prou informació per a respondre a la consulta amb certesa”.

Aquests riscos són **pitjors en conjunt**: una IA, en lloc de no donar una resposta, pot inventar-se una escena fictícia per tal de respondre a l'usuari com si tingués tot el coneixement necessari i pogués respondre-ho tot correctament. El biaix d'automatització se suma a l'equació: és un comportament típic en les persones donar una resposta per vàlida perquè l'ha generada un programa informàtic.

També cal tenir en compte que l'ús d'eines d'aquests tipus té un **cost econòmic i mediambiental elevat**. Si una tasca es pot completar amb eines més bàsiques emprant més o menys el mateix temps i obtenint un resultat similar, és preferible no fer servir la IA.

Qualitat i eficàcia

Convé saber que l'**eficàcia de la IA** depèn en gran manera de la **qualitat i el format de les dades d'entrada**.

- Donar-li **enllaços** al Copilot per tal que accedeixi a webs per extreure informació pot ser molt **pitjor** que donar-li **directament el text**, ja que estalviem al model l'**esforç i els riscos** associats d'haver de cercar la informació i filtrar-la dels documents HTML amb els quals es construeixen webs.

Capes de coneixement

Per acabar, és interessant veure com una IA pot desenvolupar o no el seu coneixement:

- Podem pensar que l'assistent es conforma de 5 capes de coneixement:
 - o Coneixement adquirit durant l'**entrenament**.
 - o Coneixement que li donen OpenAI i Microsoft amb **prompts de sistema**.
 - o Coneixement que la persona que ha creat l'agent insereix a les seves **instruccions d'agent**.
 - o Coneixement que li doneu vosaltres en les **fonts d'informació i en la conversa (prompts)**.
 - o Coneixement que aconsegueix d'**internet**, en el cas de Copilot.
- Fixeu-vos que **vosaltres** només podeu interactuar amb les **dues últimes capes**, mitjançant els **prompts i documents** que li envieu i **demanant-li que cerqui o que no cerqui a internet**. Aquest coneixement sempre es quedarà en la **conversa on envieu la informació**, per tant, no canviareu el comportament ni coneixement de l'assistent a ulls d'una altra persona usuària i, en principi, ni tan sols als vostres propis ulls quan estigueu en una altra conversa diferent.
 - o El que vol dir això és que les converses estan aïllades. No tingueu por de demanar a l'assistent que es comporti d'una certa forma o de donar-li noves fonts d'informació, ja que **iniciar una nova conversa hauria de retornar-lo a l'estat original**.


Instruccions d'ús

El primer cop:

Ens han de donar accés a l'assistent. Un cop tinguem accés, apareixerà en el nostre compte al Copilot Xat, a la llista d'assistents del menú lateral.

Ús de l'assistent:


1. Amb connexió a internet, anar a la pàgina de Copilot Xat
(<https://m365.cloud.microsoft/chat>)
i fer clic l'**Assistent CQS SAIEP** per obrir una nova conversació.



Il·lustració 1: Menú lateral a Copilot Xat

Ens sortirà aquest menú amb alguns botons a sota:

Aquests botons de sota serveixen per fer servir un **prompt prefabricat**, i per donar-vos idees de quines coses podeu fer amb l'assistent.



Il·lustració 2: Interfície de conversa amb l'assistent

2. Un cop per conversa, s'han de pujar els documents que vulguem fer servir com a fonts d'informació per a l'agent.
 - a. La **font bàsica**, que s'ha fet amb cura i revisió per part dels caps, és l'arxiu [fonts_assistent_copilot.md](#). Per tal de fer servir sempre la versió actualitzada, no feu còpies d'aquest arxiu.
 - i. Per donar a l'assistent el document, arrossegueu-lo des de l'explorador d'arxius de Windows.
 - b. Vosaltres també podeu **crear i anar actualitzant els vostres propis arxius** amb fonts d'informació addicionals, com ara un registre de consultes i respostes donades que vulgueu fer servir d'exemple. Tingueu en compte que:
 - i. **La qualitat de les fonts és molt important**. Si veieu que l'assistent es comporta de forma inesperada, potser té a veure amb les fonts que li doneu. Més avall es donen detalls sobre la qualitat de les fonts.
 - ii. **És imprescindible que no hi inseriu dades personals en aquestes fonts**. Altrament, es podria estar vulnerant el Reglament General de Protecció de Dades (RGPD). Més avall es donen detalls sobre les dades personals.
3. Ja podeu fer consultes.

Per fer una consulta, és fonamental que primer es faci un procés **d'anonimització de dades personals**:

- Totes les **dades** que estiguin **associades a una persona** o permetin identificar-la en un cert context són dades personals. Exemples:
 - Nom i cognoms del ciutadà.
 - DNI, NIE, passaport o altres documents identificadors de la persona.
 - Vies de contacte com telèfons mòbils o correus electrònics.
 - Adreces de la persona o d'instal·lacions o altres immobles de les quals sigui titular.
 - Números de tràmit o expedient.

- Números de registre o d'instal·lació (CAU, RAC, RITSIC...).
- Matricules de vehicles, referències cadastrals, números de contracte, números de comptador, dades bancàries, identificadors de subministrament...

Aquestes dades:

- **S'han d'esborrar, en general**, per a respondre la consulta al ciutadà, **excepte si són necessàries** per a la resposta.
 - **En cas que es donin al Copilot, la conversa s'ha d'esborrar** un cop s'ha donat resposta al ciutadà.
 - Per esborrar una conversa, des del menú lateral, a la secció de "Xats", hem de posar el ratolí a sobre de la conversa, clicar la icona dels **tres punts** i seleccionar "**Suprimeix**".
- **S'han d'esborrar, sempre, si s'inclouen en un registre** de converses o qualsevol altra font que intervingui per donar resposta a un ciutadà diferent.

Tingueu en compte els **riscos** de l'assistent (**al·lucinacions**), i verifiqueu sempre la seva resposta:

- Comproveu que les **fonts** que dona efectivament **existeixen i contenen el contingut esmentat**.
- Comproveu el **fil lògic**: ha de ser coherent i sense fal·làcies ni altres trucs.
- Verifiqueu que el **format** i l'**estil** de la resposta són els esperats.
 - Si la resposta **no té la signatura completa del servei** o **no s'estructura en dues parts** clarament i explícitament diferenciades, és molt probable que **estigueu conversant amb el Copilot genèric** en comptes de l'assistent per CQS. La interfície del Copilot Xat pot tenir errors i potser no converseu amb l'assistent.

Es recomana que aprofiteu els **botons per copiar el text** que trobareu a múltiples punts de la interfície: 

Recordeu que podeu interactuar amb l'assistent de formes diverses. Podeu provar, per exemple, de demanar-li que **refaci una resposta** incloent o excloent una certa informació, que us faci una **explicació més en detall** del seu raonament, que us faci un **resum de les seves fonts d'informació**...

4. El coneixement que adquireix l'assistent s'acumula al llarg d'una conversa. És **imprescindible iniciar una nova conversa** per a cada consulta d'un **ciutadà diferent**.

Procés de l'assistent i resultats esperats

Les instruccions de l'assistent detallen els passos que ha de realitzar per respondre una consulta. En resum, són aquests:

1. Entendre la consulta
2. Filtrar la consulta
3. Cercar a les fonts d'informació
4. Decidir la capacitat de respondre
5. Elaborar la resposta

El pas 2 consisteix a comprovar si el tema del qual tracta una consulta es troba dins de la *blacklist*: una llista de temes que s'han de derivar a altres organismes responsables de donar resposta.

- Per tant, un possible resultat esperat és que l'assistent ens digui que **la consulta s'ha de derivar a un organisme determinat**.

En el pas 4, l'assistent està instruït per decidir si, amb la informació disponible, té sentit donar una resposta al ciutadà. Potser no sap com respondre una consulta, o potser cal informació específica sobre algun tràmit que heu de consultar manualment.

- Un possible resultat esperat és que l'assistent digui que **no pot donar resposta al ciutadà per falta d'informació**.

En **cas que sí que pugui donar resposta al ciutadà**, veurem una resposta amb **2 parts**:

- Part 1: raonament i fonts utilitzades
- Part 2: resposta a la consulta ciutadana

La part 1 ens serveix a nosaltres per veure la justificació que es fa de la part 2. Aquesta part 2 és la que podem enviar al ciutadà, si cal, fent algunes modificacions pel seu cas específic o arreglant errors.

Quines fonts d'informació fa servir l'assistent?

Per defecte (recordeu que vosaltres podeu fer servir altres documents) l'agent fa servir informació de 3 procedències diferents, ajuntades a l'arxiu **fonts_assistent_copilot.md**:

1. Seccions de FAQs del servei
2. Resum dels tràmits del servei
3. *Blacklist*

Els tres elements s'han fet manualment i amb cura, i estan en format Markdown (.md) un format de text bàsic enriquit amb estils i *hyperlinks*, estandarditzat com a format per a fer servir amb la IA. La font bàsica és d'alta qualitat perquè el format que s'ha fet servir permet al model distingir i entendre bé la informació i hi ha poca informació repetida.

Altres potencials dubtes

- **Podem donar dades privades a l'assistent?**

Només si són necessàries. En principi, el símbol de l'escut verd indica que la conversa és segura i que no es faran servir les dades per entrenar futurs models d'IA. Així i tot, tota mesura de seguretat addicional és positiva: si esborrem les dades privades, ens assegurem que no es poden filtrar de cap forma en noves respostes que ens doni el nostre assistent, i estem reduint la superfície d'un possible ciberatac que tingui l'objectiu de robar dades. Sota el RGPD, només usem l'eina correctament si esborrem totes les dades que no siguin necessàries per a la finalitat a aconseguir.

- **Què és la “qualitat de les fonts d'informació”?**

La qualitat d'una font d'informació té un significat ampli. Una font d'alta qualitat, entre altres coses:

- Conté la **informació necessària**, sense repetir informació ni obviar informació imprescindible.
- Té un **format fàcilment interpretable** per la IA, preferiblement Markdown (.md) o, si convé, text bàsic (.txt) taules en .csv, EXCEL, WORD o similars, amb una estructura que clarament diferencia títols, seccions, preguntes, respostes...
 - **Markdown** és l'**estàndard** i facilita donar format al text de forma que la IA l'interpreti fàcilment, gràcies a l'organització en títols i seccions (#, ##...).
 - **.txt** és ideal per **fonts curtes**, on per donar format podem simplement indicar “Títol: ...”, “Secció 1: ...” i similars.

- **.csv** és ideal per contingut organitzat en **taules**.
- Podem fer servir **EXCEL, WORD o similars**, però **afegirem treball a l'assistent** perquè són formats més complexos.
- Fer servir **webs no es recomana en general** i, si es fa, s'han de fer proves que validin que l'assistent està accedint a la informació correctament.
- No conté faltes d'ortografia, gramaticals o de sintaxi. Idealment, està escrita en una mateixa llengua (podem tenir seccions en diferents llengües i no hauria de ser un problema).

- **Com puc llegir i editar un arxiu Markdown (extensió .md)?**

A l'explorador d'arxius el seleccionem, fem **clic dret**, "**Obre amb**" -> "**Llibreta**" per veure-ho en format cru. Veurem símbols com # o estructures com (text)[link]. Això és el que processa la IA, però tenen un significat estandarditzat. Si volem tenir una idea intuïtiva sobre què representa aquest format, podem descarregar i instal·lar [**Microsoft Visual Studio Code**](#) (recomanat) o [**Obsidian**](#) per obrir els arxius i veure'ls amb el format aplicat (veuríem els títols, separadors i *hyperlinks*). Es recomana per servir aquest format per a les fonts, fent servir títols i seccions.

- **Com sé si el document que estic fent és de bona qualitat per a l'agent?**

Una forma senzilla de comprovar si l'assistent aprofita la informació que li envies és obrint un **nou assistent**, enviant **només aquesta font**, i fent preguntes que validin que comprèn la font i que la sap fer servir (com ara mitjançant preguntes de les quals tu ja saps la resposta, o demanant que faci un resum de la font proporcionada).

- **Cal fer servir aquestes fonts i aquest assistent?**

Sí, en general, és necessari. Tant les instruccions de l'assistent com els documents per fer servir com a fonts milloren substancialment el comportament de l'assistent. Ometre qualsevol d'aquestes dues té un alt risc de donar respostes incorrectes, augmenta molt els riscos d'inserir al·lucinacions en la resposta i és possible que dificulti el treball en comptes d'ajudar-nos. **Podeu fer proves** per comparar les respostes de diferents formes, per exemple amb el Copilot genèric o sense donar-li les fonts, i comprovar com canvia el comportament. Generant una nova conversa amb l'assistent restablireu el comportament original.

- **És possible que el comportament de l'assistent canviï de forma inesperada?**

Sí, tant Microsoft com OpenAI poden fer canvis en la plataforma que poden afectar el comportament, com ara canvis en els *prompts* de sistema o canvis en el model (per exemple actualitzar de GPT 5.5 a GPT 5.6). Normalment, no se us notificaran aquests canvis. Així i tot, les instruccions de l'agent i les fonts tindran molt pes en el comportament, i sempre (excepte si demanem el contrari a l'assistent) hauríem de veure una resposta estructurada en dues parts explícites i la signatura correcta. Si no és el cas, proveu d'obrir una nova conversa amb l'assistent i fer servir només la font `fonts_assistent_copilot.md`.