

Instruccions per fer servir l'agent de Copilot **Assistent CQS SAIEP**

(Assistent per a la plataforma de consultes, queixes i suggeriments del Servei d'Autorització d'Instal·lacions Elèctriques de Producció).

Versió inicial feta per Àngel Morales Cirera

(angelmorales@gencat.cat | angel.morales@estudiantat.upc.edu)

Introducció

En aquest document s'explica com fer servir l'assistent i unes directrius bàsiques per maximitzar l'eficiència, esprémer el potencial, i minimitzar els riscos.

L'accés a l'assistent pot estar restringit a una llista de persones específiques.

Aspectes importants a conèixer

Aquest agent de Copilot Xat té l'objectiu d'accelerar el procés de donar resposta a una consulta ciutadana a través del CQS, fent eficient tant la cerca d'informació necessària per donar resposta com la síntesi d'aquesta resposta.

Principals riscos

És **primordial comprendre** que aquest assistent està basat en **intel·ligència artificial**, per tant, no pensa com una persona i no es comporta com una persona, encara que el seu raonament s'assembli al que fem nosaltres. Les diferències clau són aquestes:

- **No pot fer-se responsable** de les conseqüències d'allò que fa. Sempre s'haurà de fer servir com una eina d'assistència, i mai no podrem delegar-li cap mena de responsabilitat.
- **Pot cometre errors** que una persona és més difícil que cometi, i d'una forma que els fa difícils de percebre, com ara:

- **Al·lucinacions:** inventar-se sense voler informació que no és certa, com ara una llei o un article d'una llei, i fer-la servir com si existís de veritat. Si bé una persona també pot confondre's i inventar-se afirmacions, els errors humans acostumen a ser puntuals (per exemple confondre una data, un nom, una llei...), però una al·lucinació d'una IA a vegades comporta crear tota una escena fictícia sencera (com ara inventar-se l'existència d'un article d'una llei). Això ens pot resultar confús i pot ser més difícil adonar-se'n, ja que típicament una persona només faria això de forma deliberada per mentir.
- **Pot tenir un comportament molt diferent del d'una persona.** Per exemple, **una IA acostuma a respondre sempre** a una pregunta que se li faci, **en comptes de dir que “no ho sap”** com fa una persona. Per aconseguir que una IA no doni resposta (digui “no ho sé”) se li ha de demanar específicament, per exemple demanant-li que “respongui que no té prou informació per a respondre a la consulta amb certesa”.

Aquests riscos són **pitjors en conjunt**: una IA, en lloc de no donar una resposta, pot inventar-se una escena fictícia per tal de respondre a l'usuari com si tingués tot el coneixement necessari i pogués respondre-ho tot correctament. El biaix d'automatització se suma a l'equació: és un comportament típic en les persones donar una resposta per vàlida perquè l'ha generada un programa informàtic.

També cal tenir en compte que l'ús d'eines d'aquests tipus té un **cost econòmic i mediambiental elevat**. Si una tasca es pot completar amb eines més bàsiques emprant més o menys el mateix temps i obtenint un resultat similar, és preferible no fer servir la IA.

Qualitat i eficàcia

Convé saber que l'**eficàcia de la IA** depèn en gran manera de la **qualitat i el format de les dades d'entrada**.

- Donar-li **enllaços** al Copilot per tal que accedeixi a webs per extreure informació pot ser molt **pitjor** que donar-li **directament el text**, ja que estalviem al model l'**esforç i els riscos** associats d'haver de cercar la informació i filtrar-la dels documents HTML amb els quals es construeixen webs.

Capes de coneixement

Per acabar, és interessant veure com una IA pot desenvolupar o no el seu coneixement:

- Podem pensar que l'assistent es conforma de 5 capes de coneixement:
 - o Coneixement adquirit durant l'**entrenament**.
 - o Coneixement que li donen OpenAI i Microsoft amb **prompts de sistema**.
 - o Coneixement que la persona que ha creat l'agent insereix a les seves **instruccions d'agent**.
 - o Coneixement que li doneu vosaltres en les **fonts d'informació i en la conversa (prompts)**.
 - o Coneixement que aconsegueix d'**internet**, en el cas de Copilot.
- Fixeu-vos que **vosaltres** només podeu interactuar amb les **dues últimes capes**, mitjançant els **prompts i documents** que li envieu i **demanant-li que cerqui o que no cerqui a internet**. Aquest coneixement sempre es quedarà en la **conversa on envieu la informació**, per tant, no canviareu el comportament ni coneixement de l'assistent a ulls d'una altra persona usuària i, en principi, ni tan sols als vostres propis ulls quan estigueu en una altra conversa diferent.
 - o El que vol dir això és que les converses estan aïllades. No tingueu por de demanar a l'assistent que es comporti d'una certa forma o de donar-li noves fonts d'informació, ja que **iniciar una nova conversa hauria de retornar-lo a l'estat original**.


Instruccions d'ús

El primer cop:

- Ens han de donar accés a l'assistent. Un cop tinguem accés, apareixerà en el nostre compte al Copilot Xat, a la llista d'assistents del menú lateral.

Ús de l'assistent:

1. Amb connexió a internet, anar a la pàgina de Copilot Xat (<https://m365.cloud.microsoft/chat>) i fer clic l'**Assistent CQS SAIEP** (per obrir una nova conversació) o clicar a una conversa ja iniciada amb l'assistent.



Il·lustració 1: Menú lateral a Copilot Xat

Si obrim una nova conversació, ens sortirà aquest menú amb alguns botons a sota:

Aquests botons de sota serveixen per fer servir un **prompt prefabricat**, i per donar-vos idees de quines coses podeu fer amb l'assistent.



Il·lustració 2: Interfície de conversa amb l'assistent

2. Un cop per conversa, s'han de pujar els documents que vulguem fer servir com a fonts d'informació per a l'agent.
 - a. La **font bàsica**, que s'ha fet amb cura i revisió per part dels caps, és l'arxiu [fonts_assistent_copilot.md](#). Per tal de fer servir sempre la versió actualitzada, no feu còpies d'aquest arxiu.
 - i. Per donar a l'assistent el document, arrossegueu-lo des de l'explorador d'arxius de Windows.
 - b. Vosaltres també podeu **crear i anar actualitzant els vostres propis arxius** amb fonts d'informació addicionals, com ara un registre de consultes i respostes donades que vulgueu fer servir d'exemple.
 - i. Tingueu en compte que **la qualitat de les fonts és molt important!** Si veieu que l'assistent es comporta de forma inesperada, potser té a veure amb les fonts que li doneu. Més avall es donen detalls sobre la qualitat de les fonts.
3. Ja podeu fer consultes! Tingueu en compte els **riscos** de l'assistent (**al·lucinacions**), i verifiqueu sempre la seva resposta:
 - Comproveu que les **fonts** que dona efectivament **existeixen i contenen el contingut esmentat**.
 - Comproveu el **fil lògic**: ha de ser coherent i sense fal·làcies ni altres trucs.
 - Verifiqueu que el **format** i l'**estil** de la resposta són els esperats.
 - Si la resposta **no té la signatura completa del servei o no s'estructura en dues parts** clarament i explícitament diferenciades, és molt probable que **estigueu conversant amb el Copilot genèric** en comptes de l'assistent per CQS. La interfície del Copilot Xat pot tenir errors i potser no converseu amb l'assistent.

Es recomana que aprofiteu els **botons per copiar el text** que trobareu a múltiples punts de la interfície: 

Recordeu que podeu interactuar amb l'assistent de formes diverses. Podeu provar, per exemple, de demanar-li que **refaci una resposta** incloent o excloent una certa informació, que us faci una **explicació més en detall** del seu raonament, que us faci un **resum de les seves fonts d'informació**...

4. El coneixement que adquireix l'assistent s'acumula al llarg d'una conversa. Ens convé **iniciar una nova conversa periòdicament** o quan vulguem, per exemple:
 - a. Tenir l'assistent fresc, amb el **comportament original**.
 - b. Tenir una conversa amb unes fonts addicionals en específic.
 - c. Fer proves amb l'assistent per veure si podem aconseguir un comportament personalitzat al nostre gust.

Procés de l'assistent i resultats esperats

Les instruccions de l'assistent detallen els passos que ha de realitzar per respondre una consulta. En resum, són aquests:

1. Entendre la consulta
2. Filtrar la consulta
3. Cercar a les fonts d'informació
4. Decidir la capacitat de respondre
5. Elaborar la resposta

El pas 2 consisteix a comprovar si el tema del qual tracta una consulta es troba dins de la *blacklist*: una llista de temes que s'han de derivar a altres organismes responsables de donar resposta.

- Per tant, un possible resultat esperat és que l'assistent ens digui que **la consulta s'ha de derivar a un organisme determinat**.

En el pas 4, l'assistent està instruït per decidir si, amb la informació disponible, té sentit donar una resposta al ciutadà. Potser no sap com respondre una consulta, o potser cal informació específica sobre algun tràmit que heu de consultar manualment.

- Un possible resultat esperat és que l'assistent digui que **no pot donar resposta al ciutadà per falta d'informació**.

En **cas que sí que pugui donar resposta al ciutadà**, veurem una resposta amb **2 parts**:

- Part 1: raonament i fonts utilitzades
- Part 2: resposta a la consulta ciutadana

La part 1 ens serveix a nosaltres per veure la justificació que es fa de la part 2. Aquesta part 2 és la que podem enviar al ciutadà, si cal, fent algunes modificacions pel seu cas específic o arreglant errors.

Quines fonts d'informació fa servir l'assistent?

Per defecte (recordeu que vosaltres podeu fer servir altres documents) l'agent fa servir informació de 3 procedències diferents, ajuntades a l'arxiu **fonts_assistent_copilot.md**:

1. Seccions de FAQs del servei
2. Resum dels tràmits del servei
3. *Blacklist*

Els tres elements s'han fet manualment i amb cura, i estan en format Markdown (.md) un format de text bàsic enriquit amb estils i *hyperlinks*, estandarditzat com a format per a fer servir amb la IA. La font bàsica és d'alta qualitat perquè el format que s'ha fet servir permet al model distingir i entendre bé la informació i hi ha poca informació repetida.

Altres potencials dubtes

- **Podem donar dades privades a l'assistent?**

En principi, el símbol de l'escut verd indica que la conversa és segura i que no es faran servir les dades per entrenar futurs models d'IA. Així i tot, tota mesura de seguretat addicional és positiva: si esborrem les dades privades, ens assegurem que no es poden filtrar de cap forma en noves respostes que ens doni el nostre assistent, i estem reduint la superfície d'un possible ciberatac que tingui l'objectiu de robar dades.

- **Què és la “qualitat de les fonts d’informació”?**

La qualitat d’una font d’informació té un significat ampli. Una font d’alta qualitat, entre altres coses:

- Conté la **informació necessària**, sense repetir informació ni obviar informació imprescindible.
- Té un **format fàcilment interpretable** per la IA, preferiblement Markdown (.md) o, si convé, text bàsic (.txt) taules en .csv, EXCEL, WORD o similars, amb una estructura que clarament diferencia títols, seccions, preguntes, respostes...
 - o **Markdown** és l'**estàndard** i facilita donar format al text de forma que la IA l’interpreti fàcilment, gràcies a l’organització en títols i seccions (#, ##...).
 - o **.txt** és ideal per **fonts curtes**, on per donar format podem simplement indicar “Títol: ...”, “Secció 1: ...” i similars.
 - o **.csv** és ideal per contingut organitzat en **taules**.
 - o Podem fer servir **EXCEL, WORD o similars**, però **afegirem treball a l’assistent** perquè són formats més complexos.
 - o Fer servir **webs no es recomana en general** i, si es fa, s’han de fer proves que validin que l’assistent està accedint a la informació correctament.
- No conté faltes d’ortografia, gramaticals o de sintaxi. Idealment, està escrita en una mateixa llengua (podem tenir seccions en diferents llengües i no hauria de ser un problema).

- **Com puc llegir i editar un arxiu Markdown (extensió .md)?**

A l’explorador d’arxius el seleccionem, fem **clic dret, “Obre amb” -> “Llibreta”** per veure-ho en format cru. Veurem símbols com # o estructures com (text)[link]. Això és el que processa la IA, però tenen un significat estandarditzat. Si volem tenir una idea intuïtiva sobre què representa aquest format, podem descarregar i instal·lar [**Microsoft Visual Studio Code**](#) (recomanat) o [**Obsidian**](#) per obrir els arxius i veure’ls amb el format aplicat (veuríem els títols, separadors i *hyperlinks*). Es recomana per servir aquest format per a les fonts, fent servir títols i seccions.

- **Com sé si el document que estic fent és de bona qualitat per a l’agent?**

Una forma senzilla de comprovar si l’assistent aprofita la informació que li envies és obrint un **nou assistent**, enviant **només aquesta font**, i fent preguntes que validin que comprèn la font i que la sap fer servir (com ara mitjançant preguntes de les quals tu ja saps la resposta, o demanant que faci un resum de la font proporcionada).

- **Cal fer servir aquestes fonts i aquest assistent?**

Sí, en general, és necessari. Tant les instruccions de l'assistent com els documents per fer servir com a fonts milloren substancialment el comportament de l'assistent. Ometre qualsevol d'aquestes dues té un alt risc de donar respostes incorrectes, augmenta molt els riscos d'inserir al·lucinacions en la resposta i és possible que dificulti el treball en comptes d'ajudar-nos. **Podeu fer proves** per comparar les respostes de diferents formes, per exemple amb el Copilot genèric o sense donar-li les fonts, i comprovar com canvia el comportament. Generant una nova conversa amb l'assistent restablireu el comportament original.

- **És possible que el comportament de l'assistent canviï de forma inesperada?**

Sí, tant Microsoft com OpenAI poden fer canvis en la plataforma que poden afectar el comportament, com ara canvis en els *prompts* de sistema o canvis en el model (per exemple actualitzar de GPT 5.5 a GPT 5.6). Normalment, no se us notificaran aquests canvis. Així i tot, les instruccions de l'agent i les fonts tindran molt pes en el comportament, i sempre (excepte si demanem el contrari a l'assistent) hauríem de veure una resposta estructurada en dues parts explícites i la signatura correcta. Si no és el cas, proveu d'obrir una nova conversa amb l'assistent i fer servir només la font `fonts_assistent_copilot.md`.